

Rapport de Stage de Fin d'Études

Optimisation et Adaptation des Modèles de Langage pour des Tâches Spécifiques au Domaine

Auteur : Minh Duy Nguyen

Filière : Modélisation Mathématique & IA

Maître de stage : Milad Mozafari (Torus AI)

Date de soutenance : 05/02/2026

Jury

David Bertoin

Charles Dossal

Olivier Roustant

Plan de la Présentation

Introduction

Problème 1 : Intégration de Connaissances Externes pour les Modèles de Langage

Problème 2 : Adaptation Comportementale pour Petits Modèles

Conclusion

De la Recherche à la Pratique : Défis de l'Implémentation de l'IA en Entreprise

Constat : 95% des projets d'IA générative/LLM en entreprise échouent à générer une valeur significative.

Deux Défis Fondamentaux en NLP Spécifique au Domaine :

Lacune de Connaissances

- ▶ Données d'entraînement statiques
- ▶ Risques d'hallucinations
- ▶ Pas d'accès aux documents propriétaires

Lacune Comportementale

- ▶ Incapacité à suivre les workflows du domaine
- ▶ Dérive hors caractère

Comment combler ces lacunes avec un déploiement à ressources limitées ?

Comblar les Lacunes : Deux Approches Complémentaires

Traiter la Lacune de Connaissances

Approches Courantes :

- ▶ Pré-entraînement continu
- ▶ Ingénierie de prompts
- ▶ **Génération Augmentée par Récupération (RAG)**
- ▶ Intégration d'API

Traiter la Lacune Comportementale

Approches Courantes :

- ▶ Ingénierie de prompts complexe
- ▶ Apprentissage few-shot
- ▶ **Fine-tuning**
- ▶ RLHF

Ce travail explore les deux approches avec des applications réelles

Problème 1

Intégration de Connaissances Externes pour les Modèles de
Langage

Construction d'un Système RAG pour Documents Complexes

Problème 1 : Intégration de Connaissances Externes

Cas d'usage : Construction d'un système de QA spécifique au domaine pour documents financiers et médicaux

- ▶ **Objectif** : Permettre des réponses précises aux questions sur des documents complexes et propriétaires
- ▶ **Contraintes** : Haute précision, faible latence, déploiement économique

Questions Clés :

- ▶ Comment préserver la structure dans les documents complexes ?
- ▶ Comment garantir une haute précision avec des ressources limitées ?
- ▶ Comment traiter efficacement les données multimodales ?

Le Vrai Défi : Données Financières Complexes

Cas d'Étude 1 : Finance - Rapports GPM

Tableaux et graphiques financiers complexes

Le **chiffre d'affaires** de la ligne d'activité « santé assimilée à la vie » s'élève à 9 752 k€, en hausse de 2% à la fin 2024 par rapport à la fin 2023.

La **charge de sinistres** de la ligne d'activité « santé assimilée à la vie » s'établit à 6 410 k€ en 2024, soit une hausse de 25% par rapport à l'exercice 2023.

La **cession** a un solde négatif de 3 540 k€ en 2024, en hausse de 7% par rapport à l'exercice 2023 et expliquée par la mise en place en 2022 d'un traité de réassurance avec Allianz.

Les **frais** s'élèvent 3 084 k€ en 2024, en baisse de 14% par rapport à la fin 2023.

En conséquence, le **résultat technique net** de frais et de réassurance de la ligne d'activité « santé assimilée à la vie » s'établit à - 3 282 k€ au titre de l'exercice 2024 contre - 2 504 k€ en 2023, soit une baisse de 31%.

A.2.2.2. Résultat Rentes

Résultat de souscription (en k€)	31/12/2024	31/12/2023	Variation en %
Primes brutes	43 899	40 476	8%
Charges sinistres brutes	15 609	13 594	15%
Résultat technique brut	28 290	26 882	5%
Primes cédées	12 630	11 728	8%
Charges sinistres cédées	3 523	2 636	34%
Résultat technique cédé	9 107	9 092	0%
Primes nettes	31 269	28 747	9%
Charges sinistres nettes	12 086	10 958	10%
Résultat technique net	19 183	17 789	8%
Frais administratifs	6 451	7 883	-18%
Frais de gestion des investissements	115	118	-3%
Frais de gestion des sinistres	991	1 005	-1%

Objectif

- Recherche rapide d'informations dans les rapports financiers annuels

Défis

- Données multi-modales : bilans, tableaux, graphiques, images
- Documents longs (50-200 pages)
- Préservation des relations entre les points de données

Le Vrai Défi : Données Médicales Complexes

Cas d'Étude 2 : Santé - Catalogue CCAM

Des milliers de codes médicaux nécessitant une correspondance exacte

Objectif

- ▶ Trouver le(s) bon(s) code(s) médical/médicaux pour des scénarios cliniques donnés

Défis

- ▶ Des milliers de codes dans une structure tabulaire complexe
- ▶ Correspondance exacte de code requise
- ▶ Descriptions de codes similaires causant de la confusion

CCAM - CCAM version TED
applicables 10/2020

Code	Texte	Activité	Phase	Tarif Secteur 1 / adjuvant OPTAMOPTAM- ACD (en euro)	Tarif Hors secteur 1 / hors adjuvant OPTAMOPTAM- ACD (en euro)	Remb. en Cotisé	Accès Prestat	En 10 opér. etc.
------	-------	----------	-------	--	--	-----------------------	------------------	------------------------

1 SYSTÈME NERVEUX CENTRAL, PÉRIPHÉRIQUE ET AUTONOME

À l'exclusion de :
- analyses post-mortem
- Par anesthésie, en entier : dans l'espace subarachnoïdien
- Par anesthésie anesthésique d'un nerf, en entier : injection d'un agent pharmacologique au contact d'un nerf, par voie transcutanée
- Par bloc anesthésique continu d'un nerf, en entier : injection d'un agent pharmacologique au contact d'un nerf avec pose d'un cathéter, par voie transcutanée

1.01 ACTES DIAGNOSTIQUES SUR LE SYSTÈME NERVEUX

À l'exclusion de :
- actes diagnostiques au niveau
- des muscles squelettiques (cf. le chapitre 02)
- du larynx (cf. chapitre 06)
- du péricrâne (cf. chapitre 06)
- des muscles postérieurs (cf. chapitre 12)
- du diaphragme (cf. chapitre 12)

01.01.01 Explorations électrophysiologiques du système nerveux

01.01.01.01 Électromyographie (EMG)

Préambule : les examens électromyographiques doivent être réalisés avec un appareil comportant un système d'amplification paramétrable en gain, une étude qualitative et quantitative


AUQ001	Électromyographie par électrode de surface, sans enregistrement vidéo	1	0	Non pris en charge	Non pris en charge			✓	ATW
AUQ002	Électromyographie par électrode de surface, avec enregistrement vidéo	1	0	Non pris en charge	Non pris en charge			✓	ATW
AUQ003	Électromyographie de 1 ou 2 muscles striés au repos et à l'effort sans stimulation, par électrode aiguille	1	0	51,84	51,84			✓	ATW
AUQ004	Électromyographie de 1 ou 2 muscles striés au repos et à l'effort avec stimulation, par électrode aiguille	1	0	86,40	86,40			✓	ATW
[P, P, S, U]	Électromyographie de 3 à 5 muscles striés au repos et à l'effort sans stimulation, par électrode aiguille	1	0	85,83	85,83			✓	ATW
[P, P, S, U]	Électromyographie de 3 à 5 muscles striés au repos et à l'effort avec stimulation, par électrode aiguille	1	0	86,40	86,40			✓	ATW
[P, P, S, U]	Électromyographie de 7 muscles striés au repos et à l'effort, par électrode aiguille	1	0	74,72	85,11			✓	ATW
AUQ005	Électromyographie de 3 à 6 muscles striés au repos et à l'effort par électrode aiguille, avec mesure des vitesses de conduction motrice et de l'amplitude des réponses musculaires de 2 à 4 nerfs sans étude de la conduction proximale par électrode de surface, et mesure des vitesses de la conduction sensitive et de l'amplitude du	1	0	124,82	123,20			✓	ATW

Autres Barrières Techniques

- ▶ **Contraintes strictes de sécurité des données** : Les données sensibles et privées ne peuvent pas être exposées à ChatGPT ou aux services cloud
- ▶ **Exigences de haute précision** : L'hallucination est inacceptable dans les domaines à enjeux élevés comme la finance et la santé
- ▶ **Déploiement à ressources limitées** : Les grands modèles nécessitent des ressources computationnelles importantes, tandis que les petits modèles ont des fenêtres de contexte limitées

→ **Objectif de la Solution** : Un pipeline RAG interne unifié capable de gérer des documents complexes avec une haute précision

Pipeline RAG Simple - Approche de Référence



Configuration RAG Simple

- **Analyse** : PyPDF pour l'extraction de texte
- **Découpage** : Taille fixe (512 tokens/chunk, 50 de chevauchement)
- **Embedding** : all-MiniLM-L6-v2
- **Base Vectorielle** : ChromaDB avec recherche dense
- **Génération** : Gemma-3-12b-it

Pourquoi le RAG Simple Échoue : Problème 1 - Perte de Structure de Table

Problème : Aplatissement de la Structure de Table 2D

Table Originale :

Sous modules (en k€)	SCR 2024	SCR 2023	Évol.
Type 1	2 692	2 487	8 %
Type 2	28 377	36 221	-22 %
Diversification	-621	-586	6 %
Risque de défaut	30 448	38 121	-20 %



Sortie PyPDF :

```
Sous modules (en k€) SCR 2024 SCR 2023 Evolution
Type 1 2 692 2 487 8 %
Type 2 28 377 36 221 -22 %
Effet de diversification -621 -586 6 %
Risque de défaut 30 448 38 121 -20 %
```

Impact : Le contexte ligne/colonne est perdu, rendant difficile la compréhension des relations par les LLM

Pourquoi le RAG Simple Échoue : Problème 2 - Échec avec la Correspondance Exacte de Code

Problème : L'embedding dense a du mal avec la correspondance exacte de mots-clés

Requête Utilisateur :

🔍 HAFA006



Résultats de Recherche :

=====

 ANALYSIS OF RESULTS

=====

1 HAFA006 POSITION:

✅ Found HAFA006 at rank #3

⚠️ HYPOTHESIS PARTIALLY CONFIRMED: Ranked #3 (not #1, but still high)

2 SIMILAR CODES RANKED HIGHER:

Found 5 chunks with similar HAFA00X codes:

- Rank #1: ['HAFA004', 'HAFA002'] (score: 0.2544)
- Rank #2: ['HAFA005', 'HAFA003'] (score: 0.2315)
- Rank #3: ['HAFA007'] (score: 0.2199)
- Rank #4: ['HAFA001'] (score: 0.2107)
- Rank #5: ['HAFA009'] (score: 0.2107)

Impact : Le code exact "HAFA006" n'est pas trouvé dans les premiers résultats ; des codes sémantiquement similaires mais incorrects sont classés plus haut

Pourquoi le RAG Simple Échoue : Analyse Quantitative

Autres Problèmes :

- ▶ **Perdu au milieu** : La précision du LLM diminue lorsque le passage de vérité terrain n'est pas en position élevée dans les top-k résultats
- ▶ **Incompatibilité d'embedding multilingue** : Modèle d'embedding anglais appliqué aux documents français

Résultats Quantitatifs sur l'Ensemble de Test GPM


Métrique	Score	Interprétation
Exactitude	0.66	Seulement 66% des réponses correctes par rapport aux contextes
Pertinence	0.73	73% des réponses pertinentes à la question

Conclusion : Le RAG simple n'atteint que 66% d'exactitude — insuffisant pour les domaines à enjeux élevés


Pipeline RAG Multimodal Avancé - Vue d'Ensemble

Innovations Clés :

- ▶ Traitement de documents préservant la structure
- ▶ Résumé multimodal
- ▶ Recherche hybride combinant sémantique et mots-clés
- ▶ Reclassement par cross-encoder



Indexation Hors Ligne : Préservation de la Structure



Préservation de la Structure avec UnstructuredIO et Table Transformer :

1. **Détection de Table** : Identifier les positions des tables en utilisant YoloX/Detectron2
2. **Reconnaissance de Structure** : Reconnaître les cellules, cellules fusionnées, en-têtes vs. corps
3. **Mapping HTML** : Convertir en balises `<table>` pour un traitement LLM facile

Indexation Hors Ligne : Exemple de Préservation de Structure

Le « type 2 » prend en compte dans son calcul du risque le montant des créances en distinguant les créances de plus et celles de moins de 3 mois. Il intègre les éléments suivants :

- les créances nées d'opérations diverses ;
- les créances d'impôts et taxes.

Les tableaux ci-après présentent la répartition des expositions et la répartition du SCR de contrepartie par typologie de contrepartie au 31 décembre 2024 :

Sous modules (en k€)	SCR 2024	SCR 2023	Evolution
Type 1	2 692	2 487	8 %
Type 2	28 377	36 221	-22 %
Effet de diversification	-621	-586	6 %
Risque de défaut	30 448	38 121	-20 %

Le risque de type 2 représente 91 % du SCR de contrepartie.

Le SCR de défaut baisse de 20% à la fin 2024 et s'explique par la baisse en 2024 des contreparties de type 2 (-22%).




L'extraction de table préserve les relations spatiales

```
<table>
  <thead>
    <tr>
      <th>Sous modules (en k€)</th>
      <th>SCR 2024</th>
      <th>SCR 2023</th>
      <th>Evolution</th>
    </tr>
  </thead>
  <tbody>
    <tr>
      <td>Type 1</td>
      <td>2 692</td>
      <td>2 487</td>
      <td>8%</td>
    </tr>
    <tr>
      <td>Type 2</td>
      <td>28 377</td>
      <td>36 221</td>
      <td>-22%</td>
    </tr>
    <tr>
      <td>Effet de diversification</td>
      <td>-621</td>
      <td>-586</td>
      <td>6%</td>
    </tr>
    <tr>
      <td>Risque de défaut</td>
      <td>30 448</td>
      <td>38 121</td>
      <td>-20%</td>
    </tr>
  </tbody>
</table>
```

Sortie HTML avec structure
intacte

Indexation Hors Ligne : Résumé Multimodal



Objectif : Réduire la taille du contexte tout en préservant les informations clés


Table Originale :

Sous modules	2024	2023	Évol.
Type 1	2 692	2 487	8 %
Type 2	28 377	36 221	-22 %
Diversif.	-621	-586	6 %
Total	30 448	38 121	-20 %



Summary: "Le tableau détaille l'évolution du Solvency Capital Requirement (SCR) pour différents sous-modules entre 2023 et 2024, avec les montants exprimés en milliers d'euros (k€) et l'évolution en pourcentage.
Pour le sous-module « Type 1 », le SCR est passé de 2 487 k€ en 2023 à 2 692 k€ en 2024, affichant une évolution de 8%. Le sous-module « Type 2 » a vu son SCR passer de 36 221 k€ en 2023 à 28 377 k€ en 2024, avec une évolution indiquée de -22%.
L'« Effet de diversification » a évolué de -586 k€ en 2023 à 621 k€ en 2024, soit une évolution de 6%. Enfin, le « Risque de défaut » a diminué, passant de 38 121 k€ en 2023 à 30 448 k€ en 2024, l'évolution diminuée de -20%."

Indexation Hors Ligne : Architecture Parent-Enfant



Principe de Conception :

- ▶ **Enfant (Résumé) :** Stocké dans la base vectorielle pour une récupération efficace
- ▶ **Parent (Contenu Brut) :** Stocké dans la base de documents pour une génération détaillée

Avantage : Récupérer en utilisant des résumés concis, générer en utilisant des informations complètes


Indexation Hors Ligne : Modèle d'Embedding Multilingue

Rank (Bo...	Model	Zero-shot	Memory U...	Number of P...	Embedding D...	Max Tokens	Mean (T...	Mean (TaskT...	Bitext ...	Classification	Clustering
2	multilingual-e5-large-instruct	99%	1068	0.560	1024	514	63.22	55.08	80.13	64.94	50.75
3	embeddinggemma-300m	99%	1155	0.308	768	2048	61.15	54.31	64.40	60.90	51.17
4	bilingual-embedding-large	98%	2136	0.560	1024	514	60.96	52.92	73.55	62.77	46.49
5	KalM-embedding-multilingual-mini-v1	92%	1885	0.494	896	512	57.05	50.05	64.77	57.57	45.61
6	Solon-embeddings-large-0.1	⚠ NA	2136	0.560	1024	514	59.63	52.01	76.10	60.84	43.86
7	bge-m3	98%	2167	0.568	1024	8194	59.56	52.18	79.11	60.35	40.88
8	gte-multilingual-base	99%	582	0.305	768	8192	58.34	51.50	71.79	57.23	44.23
9	jina-embeddings-v3	99%	1092	0.572	1024	8194	58.37	50.66	65.25	58.77	45.65
10	multilingual-e5-large	99%	2136	0.560	1024	514	58.62	51.42	73.81	59.43	42.69
11	KalM-embedding-multilingual-mini-instruct-	92%	1885	0.494	896	512	56.35	49.28	64.22	57.38	45.89

Choix : Multilingual-E5-large-instruct

- ▶ 560M paramètres, entraîné sur 100+ langues
- ▶ Surpasse les autres modèles <1B params sur le benchmark multilingue MTEB
- ▶ Capacité de suivi d'instructions pour une meilleure compréhension des requêtes

Phase de Requête en Ligne



Combinaison de Deux Approches :

- ▶ **BM25 (Mots-clés)** : Correspondance exacte de termes pour les codes, noms
- ▶ **Recherche Vectorielle (Sémantique)** : Compréhension contextuelle
- ▶ **Fusion de Rang Réciproque** : Fusionner les résultats intelligemment

Processus de Reclassement :

1. La recherche hybride récupère les documents candidats
2. Le cross-encoder calcule les scores de pertinence pour chaque paire requête-document
3. Les top-k documents les plus pertinents sont envoyés au LLM pour génération

Avantage : Traite le problème "perdu au milieu" en assurant que le contexte le plus pertinent est bien classé

Configuration de l'Évaluation Expérimentale

Jeux de Données de Test

- ▶ **Ensemble de Test GPM** : 25 questions complexes sur les rapports financiers de GPM
- ▶ **Ensemble de Test CCAM** : 10 scénarios de consultation clinique (fournis par Dr. Besnier)

Évaluation LLM-as-a-Judge utilisant les Métriques RAGAS

- ▶ Deux modèles juges : `gemma-3-12b-it`, `mistral-small-24b-instruct-2501`
- ▶ Toutes les métriques sur échelle continue [0, 1], moyennées sur les deux juges

Métrique	Définition
Exactitude de Réponse	Similarité sémantique : générée vs. vérité terrain
Pertinence de Réponse	Dans quelle mesure la réponse traite la requête
Fidélité	Réponse ancrée dans le contexte récupéré
Précision du Contexte	Chunks pertinents bien classés
Taux de Réussite de Code@k	Code correct dans les top-k résultats (CCAM uniquement)

Résultats : Amélioration Supérieure de la Précision


Table – Résultats sur l'Ensemble de Test GPM (25 questions)

Pipeline	Exact.	Pert.	Fidél.	Préc.
RAG Simple	0.648	0.788	0.732	0.654
RAG Avancé	0.976	0.972	0.940	0.960
<i>Amélioration</i>	<i>+32.8%</i>	<i>+18.4%</i>	<i>+20.8%</i>	<i>+30.6%</i>

Table – Résultats sur l'Ensemble de Test CCAM (10 scénarios)

Pipeline	Taux@5	Taux@20
RAG Simple	0.4	0.6
RAG Avancé	0.8	0.9
<i>Amélioration</i>	<i>+40%</i>	<i>+30%</i>

Résultats : Comparaison Visuelle



Observations Clés :

- ▶ Le RAG avancé atteint des performances quasi-parfaites sur l'ensemble de données GPM
- ▶ Plus grandes améliorations en exactitude et précision du contexte
- ▶ Amélioration spectaculaire de la récupération exacte de code pour CCAM
- ▶ Gains cohérents sur toutes les métriques d'évaluation

Étude d'Ablation : Contribution de Chaque Composant

Table – Améliorations incrémentales sur l'Ensemble de Test GPM

Configuration	Précision	Δ vs Base	Δ Cumulatif
Référence (RAG Simple)	0.648	—	—
+ Analyse UnstructuredIO	0.762	+11.4%	+11.4%
+ Résumé	0.818	+5.6%	+17.0%
+ Embedding E5 Multilingue	0.875	+5.7%	+22.7%
+ Recherche Hybride	0.920	+4.5%	+27.2%
+ Reclassement	0.976	+5.6%	+32.8%

Insights Clés :

- ▶ La préservation de structure (UnstructuredIO) donne le plus grand gain unique (+11.4%)
- ▶ Chaque composant contribue de manière significative à la performance finale
- ▶ L'effet cumulatif démontre la valeur de la conception holistique du pipeline

Problème 2

Adaptation Comportementale et Optimisation des Ressources
pour Petits Modèles

Fine-tuning de Petits Modèles pour Tâches Spécialisées

Problème 2 : Adaptation Comportementale pour Petits Modèles

Contexte : Construction d'un chatbot pour la lecture de Tarot (conseil psychologique)

Approche Naïve : Ingénierie de prompts avec de grands LLM (GPT-4, Claude-3) via API


Pourquoi l'Ingénierie de Prompts Seule Est Insuffisante :

- ▶ **Dilution de l'attention** : Contexte important perdu dans les longs prompts
- ▶ **Inconsistance** : Dérive hors caractère dans les conversations étendues
- ▶ **Coût** : Grands modèles coûteux pour le déploiement continu

Table – Comparaison des coûts opérationnels. *10K conversations × 3K tokens chacune.
**Coût GPU amorti.


Option	Coût/1K tokens	Coût/mois*
API GPT-4-turbo	\$0.01–0.03	\$300–900
API Claude 3 Sonnet	\$0.003–0.015	\$90–450
Qwen-1.5B Fine-tuné	\$0.0005**	\$10–50

Exigences Spécifiques pour une Tâche de Lecture de Tarot



Connaissances :

Significations des cartes et tirages



Workflow : Structure de conversation stricte

Traits

Comportementaux :

- ▶ Ton empathique
- ▶ Interaction ouverte
- ▶ Éviter les prédictions directes

Exemple d'une Conversation de Tarot

Illustrative Example: Tarot Conversation

Querent: Hi, I've been feeling stuck in my job lately. I'm not sure if I should stay or look for something new.

Chatbot: Hey there! Career crossroads can be tricky, right? Before we dive into the cards, tell me a bit more — what's making you feel stuck? Is it the work itself, the environment, or something else?

Querent: It's mostly that I don't feel challenged anymore. The pay is good but I'm just going through the motions.

Chatbot: Ah, the golden handcuffs situation! That's actually really common. So you're craving growth and meaning, not just a paycheck. Got it. Ready to see what the cards have to say? Focus on your question, take a deep breath, and pick three cards when you're ready.


Querent: [Draws: The Tower (reversed), Eight of Cups, The Star]

Chatbot: Ooh, interesting spread! Let's start with The Tower reversed in your first position. Usually The Tower upright is about sudden upheaval, but reversed? It's more like... you're *avoiding* a necessary change. Maybe you already know things need to shake up, but you're holding on because it feels safer?

The Eight of Cups in the middle — this one's literally about walking away from something that no longer fulfills you. See how the figure is leaving those cups behind? That's you, being called to seek something more meaningful...

[continues with card interpretations and synthesis]

Pipeline de Distillation : Génération de Données d'Entraînement Synthétiques



Processus de Génération de Données :

- ▶ Les LLM (Qwen2.5-Plus, GPT-4o, DeepSeek-R1) génèrent 780 conversations
- ▶ Chaque conversation inclut :
 - ▶ Sujets et questions simulés des consultants
 - ▶ Longueur de conversation spécifiée
 - ▶ Traits de personnalité du consultant

Sélection du Modèle : Pourquoi Qwen2.5-1.5B-Instruct ?

Table – Performance sur benchmarks standards (Source : Rapport Technique Qwen2.5, 2024)

Modèle	Params	MMLU (Connaiss.)	GSM8K (Raisonn.)	MATH (Logique Dure)
Llama-3.2-1B-Instruct	1.23B	49.3	44.4	30.6
Gemma-2-2.6B-Base	2.6B	52.2	30.3	25.3
Qwen2.5-0.5B-Instruct	0.49B	47.5	49.6	34.4
Qwen2.5-1.5B-Instruct	1.54B	60.9	73.2	55.2

Raisons de la Sélection :

1. Ratio performance/paramètres supérieur
2. Forte capacité multilingue
3. Excellente capacité de suivi d'instructions
4. Inférence efficace sur matériel grand public

Résultats du Fine-tuning : Évaluation Complète

Table – Résultats LLM-as-a-Judge (FT = Fine-tuné)

Modèle	Style	Connaiss.	Empathie	Workflow	Cohér.	Moy
<i>Juge : Gemma-3-12B-Instruct</i>						
Qwen-0.5B (base)	0.42	0.65	0.48	0.35	0.72	0.52
Qwen-0.5B (FT)	0.78	0.72	0.81	0.85	0.80	0.79
Qwen-1.5B (base)	0.55	0.71	0.58	0.42	0.78	0.61
Qwen-1.5B (FT)	0.88	0.85	0.89	0.92	0.88	0.88
GPT-4 (prompt)	0.82	0.90	0.85	0.75	0.92	0.85
<i>Juge : Mistral-Small-24B-Instruct</i>						
Qwen-1.5B (base)	0.52	0.68	0.55	0.40	0.75	0.58
Qwen-1.5B (FT)	0.85	0.82	0.86	0.90	0.86	0.86
GPT-4o (prompt)	0.80	0.88	0.82	0.72	0.90	0.82

Résultats Clés :

- ▶ Le fine-tuning améliore considérablement les métriques comportementales, en particulier la conformité au workflow (+50% : 0.42 → 0.92)
- ▶ Qwen-1.5B fine-tuné surpasse GPT-4 avec prompts sur le style, l'empathie et le workflow
- ▶ Réduction de coût de 100x avec performance comparable ou meilleure

Application Démo utilisant Gradio

Tarot Reading

Instructions

To know about what the cards guide you, you should:

- First, try to pose concerns in the chat.
- Second, chat with the reader so that she can get to know more about your situation.
- Once the reader asks you to draw 3 cards, go down, hit the "Reset and Shuffle Cards" and choose 3 cards, and then return to type "Draw" or "Ready" or "Yes", or anything that means you're done, in the chat.
- Then continue to follow the chat to get your full reading.
- Hit the **Reset History** to refresh the chat and ask a new question.

Tap to Chat

Ahright, no problem. We can handle everything together then! Before we dive into the reading, though, let's make sure we have three cards drawn. Once you've finished drawing them, type "done" so we can start interpreting them. Sound good?

Done

Perfect! Now, let's begin. The first card we pulled is **Temperance**. This card speaks to balance and harmony—it reminds us that sometimes our biggest challenges arise because we're trying too hard to force change instead of allowing ourselves to adapt naturally. For example, imagine someone who gets stuck in a job because they think they're doing perfectly fine, even though deep down they wish things were different. Does that resonate with you at all? Or perhaps you've experienced similar hesitation before?

What's on your mind? Love, work, family, etc...



Select Model

old_data_checkpoints/Queen/Queen2.5-1.5B-Instruct-Resumed-33/checkpoint-120

Choose 3 cards to reveal your fortune!

When the chatbot tell you to draw cards, hit the shuffle button and draw 3 cards!



Fonctionnalités :

- ▶ Sélection de cartes en temps réel avec retour visuel
- ▶ Conversation multi-tours avec préservation du contexte
- ▶ Changement de modèle pour comparaison

Conclusion et Perspectives

Problème 1 : Pipeline RAG Avancé

- ▶ Développé un système RAG multimodal préservant la structure
- ▶ Atteint **32.8% d'amélioration** de l'exactitude des réponses sur les documents financiers
- ▶ Atteint **40% d'amélioration** du taux de réussite de code pour les documents médicaux
- ▶ Démontré la valeur de chaque composant du pipeline par étude d'ablation

Problème 2 : Adaptation Comportementale par Fine-tuning

- ▶ Conçu un pipeline de distillation efficace pour petits modèles
- ▶ Qwen-1.5B fine-tuné surpasse GPT-4 avec prompts sur les métriques comportementales
- ▶ Atteint **80-90% de réduction de coût** tout en maintenant une performance comparable
- ▶ Démontré la faisabilité d'agents conversationnels spécialisés sur matériel grand public

Améliorations à Court Terme :

- ▶ Évaluation étendue sur des ensembles de données spécifiques au domaine supplémentaires
- ▶ Optimisation pour le déploiement en périphérie (quantification, élagage)

Directions de Recherche à Long Terme :

- ▶ **RLHF** : Apprentissage par renforcement à partir de retours humains pour mieux aligner les sorties du modèle avec les attentes des utilisateurs
- ▶ **Génération Multimodale** : Extension au-delà du texte pour soutenir les explications visuelles (par ex. génération de graphiques dans les rapports financiers)
- ▶ **Support Multilingue** : Extension pour soutenir des bases d'utilisateurs mondiales dans plusieurs langues

Merci

Session de Questions-Réponses

Contact :

Minh Duy Nguyen

`mnguye@insa-toulouse.fr`