

End-of-studies Apprenticeship Report

Optimizing and Adapting Language Models for Domain-Specific Task

Author: Minh Duy Nguyen
Major: Mathematical Modeling & AI
Supervisor: Milad Mozafari (Torus AI)
Defense Date: 05/02/2026

Jury
David Bertoin
Charles Dossal
Olivier Roustant

From research to practice: challenges of AI implementation in business

95% AI generation/LLM project in companies fail to generate significant P&L value. [?]

2 challenges in domain-specific NLP tasks: - Knowledge Gap - Behavior Gap

Agenda



The real challenge: Complex financial and healthcare data

Case Study 1: Financial

SFCR report with complex financial tables and charts.

Le **chiffre d'affaires** de la ligne d'activité « santé assimilée à la vie » s'élève à 9 752 k€, en hausse de 2% à la fin 2024 par rapport à la fin 2023.

La **charge de sinistres** de la ligne d'activité « santé assimilée à la vie » s'établit à 6 410 k€ en 2024, soit une hausse de 25% par rapport à l'exercice 2023.

La **cession** a un solde négatif de 3 540 k€ en 2024, en hausse de 7% par rapport à l'exercice 2023 et expliquée par la mise en place en 2022 d'un traité de réassurance avec Allianz.

Les **frais** s'élèvent 3 084 k€ en 2024, en baisse de 14% par rapport à la fin 2023.

En conséquence, le **résultat technique net** de frais et de réassurance de la ligne d'activité « santé assimilée à la vie » s'établit à - 3 282 k€ au titre de l'exercice 2024 contre - 2 504 k€ en 2023, soit une baisse de 31%.

A.2.2.2. Résultat Rentes

Résultat de souscription (en k€)	31/12/2024	31/12/2023	Variation en %
Primes brutes	43 899	40 476	8%
Charges sinistres brutes	15 609	13 594	15%
Résultat technique brut	28 290	26 882	5%
Primes cédées	12 630	11 728	8%
Charges sinistres cédées	3 523	2 636	34%
Résultat technique cédé	9 107	9 092	0%
Primes nettes	31 269	28 747	9%
Charges sinistres nettes	12 086	10 958	10%
Résultat technique net	19 183	17 789	8%
Frais administratifs	6 451	7 883	-18%
Frais de gestion des investissements	115	118	-3%
Frais de gestion des sinistres	991	1 005	-1%
Frais d'acquisition	4 170	4 566	-9%
Frais généraux	-	-	N.S.
Total frais	11 727	13 573	-14%

Case Study 2: Healthcare

CCAM catalog with thousands of codes requiring exact matching.

CCAM - CCAM version T22 applicable 01/01/2023									
Code	Texte	Activité	Phase	Tarif Secteur 1 / adjuvant OPTAMOPTAM- ACO (en euro)	Tarif hors secteur 1 / OPTAMOPTAM- ACO (en euro)	Remb. de Cotisation	Remb. Précédent	Donc 10 spécif. etc.	Dégré spécif. etc.
1	SYSTÈME NERVEUX CENTRAL, PÉRIPHÉRIQUE ET AUTONOME								
	À l'exclusion de : analyse en polysomnie Par respiration : en entier ; dans l'espace subarachnoïdien Par irrigation anesthésique d'un nerf : en entier ; injection d'un agent pharmacologique au contact d'un nerf par voie transcutanée Par bloc anesthésique continu d'un nerf : en entier ; injection d'un agent pharmacologique au contact d'un nerf avec pose d'un cathéter, par voie transcutanée								
1.01	ACTES DIAGNOSTIQUES SUR LE SYSTÈME NERVEUX								
	À l'exclusion de : actes diagnostiques au lit du malade - des muscles oculomoteurs ou de la pupille (cf chapitre 02) - de la gorge (cf chapitre 06) - du péricrâne (cf chapitre 08) - des muscles pterygoides (cf chapitre 11) - de la diaphragme (cf chapitre 12)								
01.01.01	Explorations électrophysiologiques du système nerveux								
01.01.01.01	Électroneurographie (ENMG)								
	Facturation : les examens électroneurographiques doivent être pratiqués avec un appareil comportant un système d'enregistrement permettant en, idéalement, une étude qualitative et quantitative								
AUQ10101	Électroneurographie par électrode de surface, sans enregistrement vidéo	1	0		Non pris en charge	Non pris en charge			1 ATW
AUQ10102	Électroneurographie par électrode de surface, avec enregistrement vidéo	1	0		Non pris en charge	Non pris en charge			1 ATW
AUQ0101	Électroneurographie de 1 ou 2 muscles striés au repos et à l'effort sans stimulation, par électrode aiguille	1	0		51,84	51,84			1 ATW
	Formation : spécifique à cet acte en plus de la formation initiale								
AUQ0102	Électroneurographie de 1 ou 2 muscles striés au repos et à l'effort avec stimulation, par électrode aiguille	1	0		86,40	86,40			1 ATW
[P. P. S. U.]	Formation : spécifique à cet acte en plus de la formation initiale								
AUQ0103	Électroneurographie de 3 à 6 muscles striés au repos et à l'effort sans stimulation, par électrode aiguille	1	0		85,82	85,82			1 ATW
[P. P. S. U.]	Formation : spécifique à cet acte en plus de la formation initiale								
AUQ0104	Électroneurographie de 3 à 6 muscles striés au repos et à l'effort avec stimulation, par électrode aiguille	1	0		86,40	86,40			1 ATW
[P. P. S. U.]	Formation : spécifique à cet acte en plus de la formation initiale								
AUQ0105	Électroneurographie de 7 muscles striés ou plus au repos et à l'effort, par électrode aiguille	1	0		74,72	85,11			1 ATW
	Formation : spécifique à cet acte en plus de la formation initiale								
AUQ0106	Électroneurographie de 3 à 6 muscles striés au repos et à l'effort par électrode aiguille, avec mesure des vitesses de conduction motrice et de l'amplitude des réponses musculaires de 2 à 4 nerfs sans étude de la conduction proximale par électrode de surface, et mesure des vitesses de la conduction sensitive et de l'amplitude du potentiel sensitif de 2 à 4 nerfs	1	0		124,82	122,20			1 ATW
	Exploration électrophysiologique d'une atteinte du nerf médian au carpi caput								
	Formation : spécifique à cet acte en plus de la formation initiale								
AUQ0107	Électroneurographie de 7 muscles striés ou plus au repos et à l'effort par électrode aiguille, avec mesure des vitesses de conduction motrice et de l'amplitude des réponses musculaires de 2 à 4 nerfs sans étude de la conduction proximale par électrode de surface, et mesure des vitesses de la conduction sensitive et de l'amplitude du potentiel sensitif de 2 à 4 nerfs	1	0		136,78	138,64			1 ATW

Why SimpleRAG fails: An empirical analysis

Failure 1: Loss of Table Structure

Sous modules (en k€)	SCR 2024	SCR 2023	Evol.
Type 1	2 692	2 487	8 %
Type 2	28 377	36 221	-22 %
Diversification	-621	-586	6 %
Risque de défaut	30 448	38 121	-20 %

→

Extraction using PyPDF

Sous modules (en k€) SCR 2024 SCR 2023 Evolution
Type 1 2 692 2 487 8 %
Type 2 28 377 36 221 -22 %
Effet de diversification -621 -586 6 %
Risque de défaut 30 448 38 121 -20 %

Why SimpleRAG fails: An empirical analysis

Failure 2: Failure with exact code matching

🔍 HAFA006



Extraction using PyPDF

=====

📊 ANALYSIS OF RESULTS

=====

1 HAFA006 POSITION:

✅ Found HAFA006 at rank #3


⚠️ HYPOTHESIS PARTIALLY CONFIRMED: Ranked #3 (not #1, but still high)

2 SIMILAR CODES RANKED HIGHER:

Found 5 chunks with similar HAFA00X codes:

- Rank #1: ['HAFA004', 'HAFA002'] (score: 0.2544)
- Rank #2: ['HAFA005', 'HAFA003'] (score: 0.2315)
- Rank #3: ['HAFA007'] (score: 0.2199)
- Rank #4: ['HAFA001'] (score: 0.2107)
- Rank #5: ['HAFA009'] (score: 0.2107)

Advanced Multimodal RAG Pipeline



Experimental Results: Superior accuracy improvement

Bảng: Results on GPM Test Set (25 questions)


Pipeline	Correctness	Relevancy	Faithfulness	Context Precision
Simple RAG	0.648	0.788	0.732	0.654
Advanced RAG	0.976	0.972	0.94	0.96
<i>Improvement</i>	<i>+32.8%</i>	<i>+18.4%</i>	<i>+20.8%</i>	<i>+30.6%</i>

Bảng: Results on CCAM Test Set (10 scenarios)


Pipeline	Code Hit Rate@5	Code Hit Rate@20
Simple RAG	0.4	0.6
Advanced RAG	0.8	0.9
<i>Improvement</i>	<i>+40%</i>	<i>+30%</i>

Experimental Results: Superior accuracy improvement

GPM Dataset Metrics



CCAM Code Hit Rate



Ablation Study: Contribution of Each Component

Bảng: Ablation Study on GPM Test Set

Configuration	Precision	Δ vs Baseline	Cumulative Δ
Baseline (Simple RAG)	0.648	—	—
+ UnstructuredIO Parsing	0.762	+11.4%	+11.4%
+ Summarization	0.818	+5.6%	+17.0%
+ Multilingual E5 Embedding	0.875	+5.7%	+22.7%
+ Hybrid Search	0.92	+4.5%	+27.2%
+ Reranking	0.976	+5.6%	+32.8%