

End-of-studies Apprenticeship Report

Optimizing and Adapting Language Models for Domain-Specific Task

Author: Minh Duy Nguyen
Major: Mathematical Modeling & AI
Supervisor: Milad Mozafari (Torus AI)
Defense Date: 05/02/2026

Jury
David Bertoin
Charles Dossal
Olivier Roustant

From research to practice: challenges of AI implementation in business

95% AI generation/LLM project in companies fail to generate significant P&L value. [?]

2 challenges in domain-specific NLP tasks: - Knowledge Gap - Behavior Gap

How can we bridge these gaps with resource-constrained deployment?

Agenda



The real challenge: Complex financial and healthcare data

Case Study 1: Financial

SFCR report with complex financial tables and charts.

Le **chiffre d'affaires** de la ligne d'activité « santé assimilée à la vie » s'élève à 9 752 k€, en hausse de 2% à la fin 2024 par rapport à la fin 2023.

La **charge de sinistres** de la ligne d'activité « santé assimilée à la vie » s'établit à 6 410 k€ en 2024, soit une hausse de 25% par rapport à l'exercice 2023.

La **cession** a un solde négatif de 3 540 k€ en 2024, en hausse de 7% par rapport à l'exercice 2023 et expliquée par la mise en place en 2022 d'un traité de réassurance avec Allianz.

Les **frais** s'élèvent 3 084 k€ en 2024, en baisse de 14% par rapport à la fin 2023.

En conséquence, le **résultat technique net** de frais et de réassurance de la ligne d'activité « santé assimilée à la vie » s'établit à - 3 282 k€ au titre de l'exercice 2024 contre - 2 504 k€ en 2023, soit une baisse de 31%.

A.2.2.2. Résultat Rentes

Résultat de souscription (en k€)	31/12/2024	31/12/2023	Variation en %
Primes brutes	43 899	40 476	8%
Charges sinistres brutes	15 609	13 594	15%
Résultat technique brut	28 290	26 882	5%
Primes cédées	12 630	11 728	8%
Charges sinistres cédées	3 523	2 636	34%
Résultat technique cédé	9 107	9 092	0%
Primes nettes	31 269	28 747	9%
Charges sinistres nettes	12 086	10 958	10%
Résultat technique net	19 183	17 789	8%
Frais administratifs	6 451	7 883	-18%
Frais de gestion des investissements	115	118	-3%
Frais de gestion des sinistres	991	1 005	-1%
Frais d'acquisition	4 170	4 566	-9%
Frais généraux	-	-	NLS
Total frais	11 727	13 573	-14%

Case Study 2: Healthcare

CCAM catalog with thousands of codes requiring exact matching.

CCAM - CCAM version T22 applicable 01/01/2023									
Code	Texte	Activité	Phase	Tarif Secteur 1 / adhérent OPTAMCOPTAM-ACO (en euro)	Tarif Secteur 1 / hors adhérent OPTAMCOPTAM-ACO (en euro)	Remb. de l'Assur.	Remb. de l'Assur.	Don. 10	Don. 10
1	SYSTEME NERVEUX CENTRAL, PERIPHERIQUE ET AUTONOME								
	À l'exclusion de : analyse en psychiatrie Par rééducation : en externe - dans l'enceinte subspécialisée Par irrigation anesthésique d'un nerf : en externe - injection d'un agent pharmacologique au contact d'un nerf par voie transcutanée Par bloc anesthésique continu d'un nerf : en externe - injection d'un agent pharmacologique au contact d'un nerf avec pose d'un cathéter, par voie transcutanée								
1.01	ACTES DIAGNOSTIQUES SUR LE SYSTEME NERVEUX								
	- des muscles oculomoteurs ou de la pupille (cf chapitre 02) - de la gorge (cf chapitre 05) - du péricrâne (cf chapitre 05) - des muscles pérygoniens (cf chapitre 11) - du diaphragme (cf chapitre 12)								
11.01.01	Explorations électrophysiologiques du système nerveux								
11.01.01.01	Électroneurographie (ENMG) Fonctionnel : les examens électroneurographiques doivent être pratiqués avec un appareil comportant un système d'enregistrement permettant en, différé, une étude qualitative et quantitative								
AUQF001	Electroneurographie par électrode de surface, sans enregistrement vidéo	1	0		Non pris en charge	Non pris en charge		2	ATW
AUQF002	Electroneurographie par électrode de surface, avec enregistrement vidéo	1	0		Non pris en charge	Non pris en charge		2	ATW
AUQF003	Electroneurographie de 1 ou 2 muscles striés au repos et à l'effort sans stimulation, par électrode aiguille	1	0		51,84	51,84		2	ATW
	Fonctionnel : spécifique à cet acte en plus de la formation initiale								
AUQF004	Electroneurographie de 1 ou 2 muscles striés au repos et à l'effort avec stimulation, par électrode aiguille	1	0		86,40	86,40		2	ATW
[P, P, S, L]	Fonctionnel : spécifique à cet acte en plus de la formation initiale								
AUQF005	Electroneurographie de 3 à 6 muscles striés au repos et à l'effort sans stimulation, par électrode aiguille	1	0		85,92	85,92		2	ATW
[P, P, S, L]	Fonctionnel : spécifique à cet acte en plus de la formation initiale								
AUQF006	Electroneurographie de 3 à 6 muscles striés au repos et à l'effort avec stimulation, par électrode aiguille	1	0		86,40	86,40		2	ATW
[P, P, S, L]	Fonctionnel : spécifique à cet acte en plus de la formation initiale								
AUQF007	Electroneurographie de 7 muscles striés ou plus au repos et à l'effort, par électrode aiguille	1	0		74,72	85,11		2	ATW
	Fonctionnel : spécifique à cet acte en plus de la formation initiale								
AUQF008	Electroneurographie de 3 à 6 muscles striés au repos et à l'effort par électrode aiguille, avec mesure des vitesses de conduction motrice et de l'amplitude des réponses musculaires de 2 à 4 nerfs sans étude de la conduction proximale par électrode de surface, et mesure des vitesses de la conduction sensitive et de l'amplitude du potentiel sensitif de 2 à 4 nerfs	1	0		124,82	127,20		2	ATW
	Exploration électrophysiologique d'une atteinte du nerf médian au carpien								
	Fonctionnel : spécifique à cet acte en plus de la formation initiale								
AUQF009	Electroneurographie de 7 muscles striés ou plus au repos et à l'effort par électrode aiguille, avec mesure des vitesses de conduction motrice et de l'amplitude des	1	0		110,07	110,07		2	ATW

Why SimpleRAG fails: An empirical analysis

Issue 1: Loss of Table Structure

Sous modules (en k€)	SCR 2024	SCR 2023	Evol.
Type 1	2 692	2 487	8 %
Type 2	28 377	36 221	-22 %
Diversification	-621	-586	6 %
Risque de défaut	30 448	38 121	-20 %

→

Extraction using PyPDF

Sous modules (en k€) SCR 2024 SCR 2023 Evolution
Type 1 2 692 2 487 8 %
Type 2 28 377 36 221 -22 %
Effet de diversification -621 -586 6 %
Risque de défaut 30 448 38 121 -20 %

Issue 2: Failure with exact code matching

🔍 HAFA006

→

=====

ANALYSIS OF RESULTS

=====

1 HAFA006 POSITION:

✅ Found HAFA006 at rank #3

⚠️ HYPOTHESIS PARTIALLY CONFIRMED: Ranked #3 (not #1, but still high)

2 SIMILAR CODES RANKED HIGHER:

Found 5 chunks with similar HAFA00X codes:

- Rank #1: ['HAFA004', 'HAFA002'] (score: 0.2544)
- Rank #2: ['HAFA005', 'HAFA003'] (score: 0.2315)
- Rank #3: ['HAFA007'] (score: 0.2199)
- Rank #4: ['HAFA001'] (score: 0.2107)
- Rank #5: ['HAFA009'] (score: 0.2107)

Why SimpleRAG fails: An empirical analysis

Other issues:

- ▶ Lost in the middle: LLM accuracy drops when ground truth passage is not in high position in top-k.
- ▶ Multilingual embedding mismatch: English embedding model on French documents.

Quantitative results

Table: Simple RAG Performance on GPM Test Set (25 questions)

Metric	Score	Interpretation
Correctness	0.66	66% answers correct with respect to contexts
Relevancy	0.73	73% answers relevant to the question

SimpleRAG only attains 66% correctness, insufficient for high-stakes domains like finance and healthcare.

Advanced Multimodal RAG Pipeline





Figure: The advanced RAG pipeline composes of 2 phases

Offline Indexing Phase



Preserving Structure with UnstructuredIO and Table Transformer

- ▶ **Table Detection:** Identify table positions.
- ▶ **Table Structure Recognition:** Recognize lines (cells), merged cells, and classify headers vs. body.
- ▶ **HTML Mapping:** Finally, map these coordinates to `<table>` tags for easy LLM processing.

Offline Indexing Phase

Le « type 2 » prend en compte dans son calcul du risque le montant des créances en distinguant les créances de plus et celles de moins de 3 mois. Il intègre les éléments suivants :

- o les créances nées d'opérations diverses ;
- o les créances d'impôts et taxes.

Les tableaux ci-après présentent la répartition des expositions et la répartition du SCR de contrepartie par typologie de contrepartie au 31 décembre 2024 :

Sous modules (en k€)	SCR 2024	SCR 2023	Evolution
Type 1	2 692	2 487	8 %
Type 2	28 377	36 221	-22 %
Effet de diversification	-621	-586	6 %
Risque de défaut	30 448	38 121	-20 %

Le risque de type 2 représente 91 % du SCR de contrepartie.

Le SCR de défaut baisse de 20% à la fin 2024 et s'explique par la baisse en 2024 des contreparties de type 2 (-22%).




An example of table extraction using
UnstructuredIO + Table Transformer.

```
<table>
  <thead>
    <tr>
      <th>Sous modules (en k€)</th>
      <th>SCR 2024</th>
      <th>SCR 2023</th>
      <th>Evolution</th>
    </tr>
  </thead>
  <tbody>
    <tr>
      <td>Type 1</td>
      <td>2 692</td>
      <td>2 487</td>
      <td>8%</td>
    </tr>
    <tr>
      <td>Type 2</td>
      <td>28 377</td>
      <td>36 221</td>
      <td>-22%</td>
    </tr>
    <tr>
      <td>Effet de diversification</td>
      <td>-621</td>
      <td>-586</td>
      <td>6%</td>
    </tr>
    <tr>
      <td>Risque de défaut</td>
      <td>30 448</td>
      <td>38 121</td>
      <td>-20%</td>
    </tr>
  </tbody>
</table>
```


HTML output

Offline Indexing Phase

Summarization for images and tables



Offline Indexing Phase




Parent-child indexing


Rank (Bo..	Model	Zero-shot	Memory U..	Number of P..	Embedding D..	Max Tokens	Mean (T..	Mean (TaskT..	Bitext ..	Classification	Clustering
2	multilingual-e5-large-instruct	99%	1068	0.560	1024	514	63.22	55.08	80.13	64.94	50.75
3	embeddingzeta-300m	99%	1155	0.308	768	2048	61.15	54.31	64.40	60.90	51.17
4	bilingual-embedding-large	98%	2136	0.560	1024	514	60.96	52.92	73.55	62.77	46.49
5	KaiM-embedding-multilingual-mini-v1	92%	1885	0.494	896	512	57.05	50.05	64.77	57.57	45.61
6	Solon-embeddings-large-0.1	NA	2136	0.560	1024	514	59.63	52.01	76.10	60.84	43.86
7	bpa-e3	98%	2167	0.568	1024	8194	59.56	52.18	79.11	60.35	40.88
8	gte-multilingual-base	99%	582	0.305	768	8192	58.34	51.50	71.79	57.23	44.23
9	jina-embeddings-v3	99%	1092	0.572	1024	8194	58.37	50.66	65.25	58.77	45.65
10	multilingual-e5-large	99%	2136	0.560	1024	514	58.42	51.42	73.81	59.43	42.69
11	KaiM-embedding-multilingual-mini-instruct-	92%	1885	0.494	896	512	56.35	49.28	64.22	57.38	45.89

MTEB benchmark: Multilingual E5 outperforms other models on multilingual tasks

Online Querying Phase



Online Querying Phase



Experimental Evaluation Setup

Test Datasets

- ▶ GPM Test Set: 25 complex questions on GPM's reports (financial domain)
- ▶ CCAM Test Set: 10 clinical consultation scenarios provided by Dr.Besnier (healthcare domain)

LLM-as-a-Judge Evaluation using RAGAS metrics

Two judge models: gemma-3-12b-it, mistral-small-24b-instruct-2501

Metric	Definition
Answer Correctness	Semantic similarity: generated vs ground-truth
Answer Relevancy	How well response addresses query
Faithfulness	Response grounded in retrieved context
Context Precision	Relevant chunks ranked highly
Code Hit Rate@k	Correct code in top-k results (CCAM)

All metrics: continuous scale [0, 1], averaged across two judges

Experimental Results: Superior accuracy improvement

Table: Results on GPM Test Set (25 questions)


Pipeline	Correctness	Relevancy	Faithfulness	Context Precision
Simple RAG	0.648	0.788	0.732	0.654
Advanced RAG	0.976	0.972	0.94	0.96
<i>Improvement</i>	<i>+32.8%</i>	<i>+18.4%</i>	<i>+20.8%</i>	<i>+30.6%</i>

Table: Results on CCAM Test Set (10 scenarios)


Pipeline	Code Hit Rate@5	Code Hit Rate@20
Simple RAG	0.4	0.6
Advanced RAG	0.8	0.9
<i>Improvement</i>	<i>+40%</i>	<i>+30%</i>

Experimental Results: Superior accuracy improvement

GPM Dataset Metrics



CCAM Code Hit Rate



Ablation Study: Contribution of Each Component

Table: Ablation Study on GPM Test Set

Configuration	Precision	Δ vs Baseline	Cumulative Δ
Baseline (Simple RAG)	0.648	—	—
+ UnstructuredIO Parsing	0.762	+11.4%	+11.4%
+ Summarization	0.818	+5.6%	+17.0%
+ Multilingual E5 Embedding	0.875	+5.7%	+22.7%
+ Hybrid Search	0.92	+4.5%	+27.2%
+ Reranking	0.976	+5.6%	+32.8%

- ▶ Structure preservation via UnstructuredIO yields largest single gain (+11.4%).
- ▶ Summarization, hybrid search and reranking also contribute significantly.

Problem 2: Behavior Gap

Present the case of building a domain-specific chatbot for Tarot Reading.
Why prompt engineering alone is insufficient:

- ▶ Attention dilution:
- ▶ Inconsistency: Out-of-character drift in extended conversations
- ▶ Cost: Large models (GPT-4) expensive for continuous deployment

Table: Operational cost comparison. *Assuming 10K conversations $\times$ 3K tokens/conversation. **Amortized GPU cost.

Option	Cost/1K tokens	Cost/month*
GPT-4-turbo API	\$0.01–0.03	\$300–900
Claude 3 Sonnet API	\$0.003–0.015	\$90–450
Qwen-1.5B Fine-tuned	\$0.0005**	\$10–50
Qwen-0.5B Fine-tuned (Edge)	\$0	\$0

Future Directions

- ▶ Reinforcement learning from human feedback (RLHF) to further align model outputs with user expectations.
- ▶ Edge deployment optimizations for low-latency responses in real-time applications.
- ▶ Multilingual response generation to support global user bases.
- ▶